

Tipología y ciclo de vida de los datos

¿CÓMO PODEMOS CAPTURAR LOS DATOS DE LA WEB?

arXiv-Publication Metadata, Collected via Web Scraping

Cano Jones, Alejandro¹, López Vicente, Christian²

E-mail: ¹acanojo@uoc.edu, ²clopezvice@uoc.edu

Keywords: arXiv, web-scraping, data-science

Abstract

La difusión temprana de resultados científicos ha sido transformada por repositorios como *arXiv*[1], que permiten el acceso a preprints en múltiples disciplinas. Este proyecto presenta la recopilación de metadatos de 3.397 preprints en la categoría *math* publicados entre mayo y junio de 2025, utilizando el módulo Python propio *arxivscraper*[2]. La información se obtuvo mediante técnicas de web scraping con *requests* y *BeautifulSoup* y se almacena en formato .csv, generando un conjunto de datos estructurado y reutilizable para estudios posteriores.

1 Introducción y contextualización

La comunicación y difusión de resultados científicos constituye un pilar fundamental para el avance del conocimiento. Tradicionalmente, los hallazgos se publicaban en revistas académicas revisadas por pares, lo que garantiza la validez y la calidad de los trabajos, pero a su vez implicaba procesos largos y costosos tanto para los autores como para los lectores. Esta dinámica ha motivado que los investigadores busquen vías alternativas para compartir sus descubrimientos de manera más ágil, especialmente dentro de comunidades especializadas o entre colaboradores cercanos, inicialmente mediante intercambios directos o correspondencia postal.

Con la expansión de la World Wide Web en la década de 1990, surgieron mecanismos de distribución más eficientes, como listas de correo electrónico y servidores de preprints, que permitieron un acceso temprano a los trabajos científicos sin esperar a la publicación formal. En este contexto, en 1991 Paul Ginsparg fundó el repositorio xxx.lanl.gov, qué más tarde pasaría a denominarse *arXiv*. Este espacio digital centralizó la difusión de preprints, entendidos como versiones preliminares de artículos científicos aún no revisados por pares, pero disponibles para su consulta y uso por la comunidad investigadora.

Si bien *arXiv* tuvo un inicio centrado en la física, su alcance se amplió progresivamente a disciplinas como matemáticas, informática, estadística, biología cuantitativa y otras áreas del conocimiento. La plataforma no solo facilitó el acceso temprano a los resultados, sino que también promovió una cultura de intercambio abierto, acelerando la diseminación de ideas y fomentando colaboraciones interdisciplinarias. Su impacto se ha evidenciado especialmente en situaciones de urgencia científica, como durante la pandemia de COVID-19, cuando la difusión inmediata de resultados preliminares permitió una respuesta más rápida en investigación y desarrollo sin depender de los plazos tradicionales de las revistas académicas.

La relevancia histórica y funcional de *arXiv* lo convierte en un objeto de estudio particularmente interesante para proyectos de análisis bibliométrico y web scraping. Al recopilar y analizar metadatos de preprints, es posible explorar patrones de colaboración entre investigadores, tendencias temáticas dentro de distintas áreas de conocimiento y la evolución de líneas de investigación a lo largo del

tiempo. Este proyecto se enfoca en la recopilación de metadatos de preprints en la categoría *math*, ofreciendo un recurso que permite examinar no sólo la producción científica, sino también la dinámica de la comunicación académica en un entorno digital.

Una fuente de inspiración para este proyecto fue el artículo “Web Scraping and Data Collection from *arXiv* Articles” publicado en Medium por Ahmed Bargady [3], en el que se describe la extracción y estructuración de datos desde *arXiv* para análisis posteriores. Este estudio confirma la viabilidad de nuestro enfoque y permite comparaciones con nuestro conjunto de datos centrado en la categoría *math* (mayo-junio 2025). A partir de ello, se plantean preguntas concretas: ¿qué etiquetas temáticas dominan en matemáticas?, ¿cómo se distribuyen los autores por artículo?, o ¿cómo se comporta la colaboración científica en comparación con otros ámbitos estudiados por Bargady? Esta comparación fortalece la justificación del proyecto y sitúa nuestra investigación en un contexto académico más amplio. Otra fuente de inspiración relevante es el repositorio de GitHub “arxiv_summarizer” de Shaier[4], que proporciona un script en Python para extraer y resumir artículos de *arXiv* utilizando la API Gemini. Este proyecto demuestra cómo automatizar la recopilación de información de preprints y generar resúmenes de manera eficiente, ofreciendo un enfoque complementario al nuestro, que se centra en la extracción de metadatos completos de la categoría *math*. La comparación con este repositorio refuerza la utilidad del dataset para análisis de tendencias temáticas, colaboración entre autores y estudios bibliométricos más detallados. En conjunto, estas fuentes de inspiración permiten justificar la pertinencia y relevancia del dataset recopilado, además de señalar preguntas de análisis concretas que nuestro proyecto puede abordar, fortaleciendo la contribución académica de la práctica.

2 Dataset recopilado

El análisis de la producción científica requiere conjuntos de datos estructurados que permitan examinar patrones de publicación, relaciones entre autores y tendencias temáticas. Aunque *arXiv* ofrece múltiples opciones de consulta, incluyendo referencias cruzadas y enlaces a artículos relacionados, este proyecto se centró en la recopilación de un dataset modesto pero representativo, enfocado en los preprints publicados en la categoría *math* durante los meses de mayo y junio de 2025. Esta elección permite realizar un análisis temporal limitado y controlado, facilitando la validación de los datos y la exploración de patrones bibliométricos sin enfrentar la complejidad de manejar millones de registros.

Los datos recopilados incluyen los metadatos principales de cada preprint, almacenados en formato .csv para su posterior análisis. Cada registro contiene un identificador único (index), el título del artículo (title), la lista de autores (authors), las etiquetas de categoría asignadas (tags) y el resumen (abstract). Este nivel de detalle permite realizar análisis diversos, desde estudios de colaboración entre autores hasta la identificación de tendencias temáticas dentro de la disciplina matemática. A modo de ejemplo, un registro representativo del dataset podría presentarse de la siguiente manera:

```
//data-point extract
{
  'index': '2510.23607',
  'title': 'Concerto: Joint 2D–3D Self–Supervised (...)',
  'tags': ['cs.CV'],
  'authors': ['Yujia Zhang', 'Xiaoyang Wu', (...)],
  'abstract': 'Humans learn abstract concepts through (...)'
}
```

Para ilustrar de manera explícita cómo se obtienen los datos de la web de *arXiv*, se incluye a continuación una imagen de la web, señalando los elementos que corresponden a cada columna del .csv generado. De esta forma, podemos representar claramente el origen de cada atributo del dataset y facilitar la comprensión del proceso de extracción de datos:




Figure 1. Atributos empleados y localización en *advance search*.

La estructura de los datos facilita su manipulación mediante herramientas de análisis como *pandas*, así como su integración en estudios de minería de texto y modelado de redes de colaboración. La elección de un periodo específico y de una categoría concreta garantiza la homogeneidad del conjunto de datos y permite comparar los resultados con estudios bibliométricos previos sobre *arXiv* y otros repositorios de preprints [3, 4].

Para este proyecto se recopilaron un total de 3.397 preprints publicados entre mayo y junio de 2025 en la categoría *math*. El dataset está disponible públicamente en Zenodo [5] bajo el nombre *arXiv-Publication Metadata, Collected via Web Scraping (2025)*. Este recurso constituye una base sólida para explorar patrones de publicación, evaluar la distribución de temas y autores, y servir como insumo para estudios posteriores de análisis de redes y tendencias de investigación. Por otro lado, con este conjunto de datos, también se pueden crear diversas visualizaciones que ayuden a entender la estructura y las tendencias de la producción científica. Entre ellas, se podrían resaltar nubes de palabras que representen los términos más usados en los resúmenes, mapas de colaboración entre autores a través de grafos o incluso gráficos temporales que ilustren cómo las publicaciones han cambiado por subcategoría. Estas ilustraciones posibilitarían una exploración visual de la dinámica de la comunidad matemática y las líneas de investigación con más actividad en el periodo estudiado.

Finalmente, es importante tener en cuenta que el propietario del conjunto de datos es la propia plataforma *arXiv*, gestionada por la Universidad de Cornell. Para la recolección de datos se han respetado estrictamente las condiciones de uso establecidas por la web. Además, para garantizar la pertinencia y fiabilidad del dataset, se han consultado análisis previos y proyectos similares, como el artículo de Ahmed Bargady en Medium y el repositorio de GitHub “*arxiv_summarizer*” de Shaier, los cuales han servido para confirmar la viabilidad de la metodología empleada y asegurar que la estructura de los datos recopilados es adecuada.

3 Implementación y producción

La recopilación de datos de preprints de *arXiv* se llevó a cabo mediante el desarrollo de un módulo en Python denominado *arxivscraper* [2], diseñado para automatizar la extracción de metadatos desde la interfaz web del repositorio. Este módulo puede ser utilizado tanto mediante línea de comandos (CLI) como importado en otros proyectos de Python, lo que proporciona flexibilidad para distintos tipos de análisis y escenarios de uso.

Para la implementación se emplearon las librerías *requests* y *BeautifulSoup*, esenciales para la obtención y el parseo de las páginas HTML de *arXiv*. La librería *requests* permite enviar solicitudes HTTP y recibir respuestas de manera eficiente, mientras que *BeautifulSoup* facilita la navegación por el contenido HTML y la extracción de los elementos de interés, como títulos, autores, categorías y resúmenes. Finalmente, *pandas* se utilizó para estructurar los datos y almacenarlos en formato .csv, asegurando su compatibilidad con herramientas de análisis posteriores.

Para visualizar de manera clara cómo se generó el dataset, se presenta un esquema que ilustra el flujo completo del proyecto. Este esquema muestra el proceso desde la captura de los datos en la

web de *arXiv*, hasta la generación del archivo .csv que será utilizado en análisis posteriores (como la Práctica 2):




Figure 2. Esquema de flujo de trabajo.

El diagrama permite comprender de forma rápida las etapas principales del proyecto y la relación entre la fuente de datos, el código implementado y el dataset resultante.

El flujo general del módulo consiste en generar la URL de búsqueda correspondiente a las fechas y categorías seleccionadas, procesar la respuesta HTML para identificar la cantidad total de resultados, y recorrer todas las páginas de resultados en bloques de 200 preprints por solicitud. Para cada preprint se extraen los metadatos definidos y se almacenan de forma estructurada. Con el fin de cumplir con las normas de uso de *arXiv* y minimizar la carga sobre sus servidores, el script incorpora una espera de 15 segundos entre cada solicitud, siguiendo las directrices establecidas en el archivo robots.txt del repositorio. Esta práctica no solo garantiza el cumplimiento de la normativa de *arXiv*, sino que también se alinea con buenas prácticas éticas de web scraping, evitando impactos negativos en la disponibilidad del servicio para otros usuarios.

A pesar de la efectividad del enfoque basado en web scraping, este método presenta limitaciones inherentes. Por ejemplo, las búsquedas avanzadas a través de la interfaz web no permiten filtrar por subcategorías de manera tan precisa como la API oficial de *arXiv*, la cual ofrece funcionalidades más robustas, incluyendo búsquedas refinadas por subcategorías, rangos de fechas específicos y opciones de paginación optimizadas. La API también reduce la necesidad de procesamiento manual del HTML y disminuye los riesgos de sobrecarga del servidor, proporcionando una alternativa más eficiente y formalmente soportada para la obtención de datos a gran escala.

El pseudo-código general del algoritmo implementado se presenta a continuación, ilustrando las etapas principales del proceso de extracción de datos:

Algorithm 1 *arxivscraper*: flujo general de extracción de metadatos

```

1: procedure arxivscraper(start_date, end_date, category, output, cross_list)
2:   url0 ← GetURL(start_date, end_date, category, cross_list)
3:   soup ← GetSoup(url0)
4:   total ← NumberOfResults(soup)
5:   if total is None then
6:     raise Error("No se encontraron resultados")
7:   end if
8:   for start in 0..total step 200 do
9:     url ← GetURL(..., start)
10:    page ← GetSoup(url)
11:    for each result in SelectResults(page) do
12:      extraer index, title, tags, authors, abstract
13:      guardar metadata-structure
14:    end for
15:    Sleep(15)
16:   end for
17:   SaveCSV(output)
18: end procedure

```

El resultado final es un archivo .csv que contiene los metadatos completos de los preprints consultados, proporcionando un recurso estructurado y reutilizable para análisis bibliométricos, estudios de redes de colaboración y exploración de tendencias de investigación. A pesar de sus limitaciones en comparación con la API oficial, el método implementado demuestra que es posible generar conjuntos de datos consistentes y valiosos utilizando técnicas de web scraping de manera responsable y ética.

De hecho, para este proyecto hemos escogido la licencia CC BY-NC-ND 4.0 debido a que es la que mejor se adecúa a la naturaleza no comercial y académica del trabajo. Esta licencia asegura que la autoría del proyecto sea reconocida (BY), prohíbe su utilización con propósitos comerciales (NC) y previene que se produzcan obras derivadas o cambios sin permiso (ND). Dado que los datos extraídos proceden de *arXiv*, es importante mantener la integridad y el propósito original de la información. Por ello, la cláusula ND contribuye a proteger tanto el contenido original de los autores como la estructura de los datasets generados. En conjunto, esta licencia permite compartir el proyecto y sus resultados de forma libre para fines educativos o de investigación, al mismo tiempo que respeta los principios éticos y legales del uso responsable de datos académicos.

References

- [1] arXiv 2025 arxiv e-print archive <https://arxiv.org/> accessed: 2025-11-08
- [2] Cano Jones A and López Vicente C 2025 Pract_1.: Web scraping [source code] https://github.com/clopezvice/PRACT_1.-WebScraping/tree/main accessed: 8Nov2025
- [3] Bargady A 2023 Web scraping and data collection from arxiv articles artículo de blog en Medium URL <https://medium.com/@bargadyahmed/web-scraping-and-data-collection-from-arxiv-articles-3d3f3e2532ec>
- [4] Shaier 2025 arxiv_summarizer: Python script to extract and summarize arxiv articles using gemini api GitHub repository URL https://github.com/Shaier/arxiv_summarizer
- [5] Cano Jones A and López Vicente C Nov 2025 arxiv-publication metadata, collected via web scraping (2025) URL <https://doi.org/10.5281/zenodo.17557644>
- [6] Subirats Maté L and Calvo González M Web scraping Barcelona módulo/Recurso Académico
- [7] Lawson R *Scraping the data* chap 1,2